算力服务器使用指北

By 徐纪元

一、使用 Torch 和 python 进行深度学习

1 创建环境

首先选择环境:



只需要 torch 就使用左边这个,需要 conda 和 ollama 就使用右边这 2 个



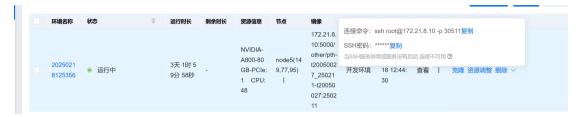
注意需要填写环境变量 NVIDIA_DRIVER_CAPABILITIES: compute,utility, shm_size 为 32(训练模型需要较大 docker 内存)



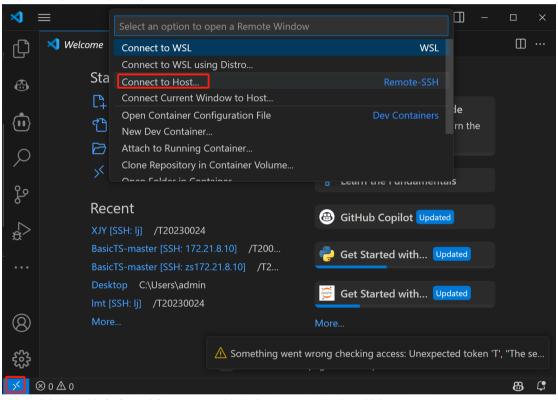
端口转发按需填写,但是也只能校内访问。

2 等待环境运行

本地电脑安装 vs code 和 xftp,参考 https://172.21.8.10:32108/zh-CN/user/user-tool/vscode-use.html 使用远程连接



在 vs code 安装 Remote SSH, 注意 windows 用户名为英文, 注意清空 C:\Users\admin\.ssh\known_hosts 文件内容



填写对应的连接命令,选择 linux,输入密码即可。多个环境如下配置:

3 连接环境文件和端口

在 xftp 输入下述信息:



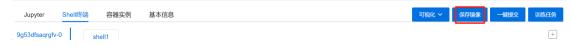
密码从平台获取, 账号写自己的, 就可以上传文件。密码过期就连不上了, 重置密码就可以。



端口访问请点击环境,具体看看"节点 ip"是多少,而不是 172.21.8.10,然后访问 http://172.21.8.4:30180/即可,容器内部端口为8080,需要在创建环境前设置。

4 使用

可以使用 nvitop 监控运行,直接 python 或 pip 使用运行文件。每次重启都是镜像的初始状态,如果需要保存新安装的软件,点击:



期间会无法访问开发环境,下次用新保存的镜像启动即可。

5 纠错

如果遇到驱动问题,如 Segmentation fault(core dumped)之类的,请参考以下命令: sudo find / -name libcuda.so*

ls /usr/lib/x86_64-linux-gnu/libcuda.so.1 -la

ls /usr/lib/x86_64-linux-gnu/libcuda.so -la

将列出的文件 libcuda.so.565.57.01 填到下面

sudo ln -f -s /usr/lib/x86_64-linux-gnu/libcuda.so.565.57.01 /usr/lib/x86_64-linux-gnu/libcuda.so

正确链接驱动即可,一般是 L40s 和 H800 节点采用不同版本驱动造成的。当然也有可能是 代码里面指针溢出,检查 dict 多线程取值和重复计算梯度问题。

开放端口运行 ollama 参考:

export OLLAMA_HOST=0.0.0.0:11434 nohup ollama serve & nohup ollama pull deepseek-r1:32b & ollama pull mxbai-embed-large ps -ef |grep ollama

运行 openwebui:

export LD_LIBRARY_PATH=/usr/lib/x86_64-linux-gnu:\$LD_LIBRARY_PATH conda create -n ds python=3.11 conda activate ds pip install open-webui open-webui open-webui serve export HF_ENDPOINT="https://hf-mirror.com" /bin/bash -c "source ~/anaconda3/bin/activate ds && open-webui serve" ps -aux | grep "open-webui serve"

临时使用升级库镜像:

sudo vi /etc/apt/sources.list deb http://mirrors.aliyun.com/ubuntu/ jammy main sudo apt update sudo apt install libstdc++6 sudo apt install libcurl4